

SPRAWOZDANIE 1

Sztuczna inteligencja i inżynieria wiedzy

Autor: Paweł Wyszomierski 228086

Prowadzący laboratoria: Mgr inż. Marcin Kulisiewicz

Termin: Wtorek 7:30

Ćwiczenie numer 1 polegało na implementacji modelu algorytmu genetycznego i przetestowaniu jego działania dla różnych parametrów.

Parametry:

numberOfPopulation - wielkość populacji w każdej generacji

mutationChance - szansa, że genotyp ulegnie mutacji

numberOfGenerations – ilość generacji

crossingChance – szansa, że dwa genotypy ulegną krzyżowaniu

tournamentAmount – ilość elementów branych do turnieju

W mojej implementacji krzyżowanie polega wylosowaniu dwóch liczb (maksymalna wartość to wielkość genotypu). Określają one początek i koniec fragmentu genotypu rodzica 1, który będzie przeniesiony na to samo miejsce do dziecka 1. Pozostałe geny dziecka 1 uzupełniane są z genotypu rodzica 2. W przypadku dziecka 2 jest odwrotnie.

Zaimplementowana mutacja polega na zamianie dwóch losowych genów w genotypie.

Wyniki otrzymane dla poszczególnych 5 plików przy parametrach:


numberOfPopulation=500

mutationChance = 2%


numberOfGenerations = 100

crossingChance = 70%


tournamentAmount = 5




Wykres 1




Wykres 2



Wykres 3



Wykres 4



Wykres 5


Wnioski: Dla tak ustawionych parametrów z wykresu widzimy, że to jak szybko znajdziemy optimum zależy od liczby genów w genotypie. Dla 12 genów (Wykres 1) wystarcza nam około 40 generacji aby dojść do wartości bardzo bliskiej lub równej optimum. W przypadku 20 genów (Wykres 5) widzimy, że po 100 generacjach wynik może być nie do końca zadowalający dlatego możemy stworzyć dodatkowe generacje które powinny poprawić zbliżyć nasz wynik do optimum. Wybrane parametry nigdy nie będą uniwersalne i dobre dla każdej wielkości genotypu dlatego powinniśmy je dopasowywać aby łatwiej uzyskać zadowalającą wartość.

Badanie wpływu parametru krzyżowania i mutacji na wynik

Parametry oprócz crossingChance oraz mutationChance nie uległy zmianie względem podanych na początku sprawozdania.

crossingChance = 0%


mutationChance = 0%



Wykres 6

crossingChance = 0%


mutationChance = 2%



Wykres 7

crossingChance = 70%

mutationChance = 70%



Wykres 8


Wnioski: Gdy prawdopodobieństwo krzyżowania będzie równe 0% oznacza to, że kolejne generacje będą składać się z tych samych genotypów co sprawi, że nie będziemy mogli uzyskać nowych genotypów, przy pomocy crossowania, które mogą być lepsze. Dodatkowo, gdy w takiej sytuacji prawdopodobieństwo mutacji wynosi 0% to kolejne generacje będą posiadać tą samą populację przez co nie będziemy w stanie uzyskać lepszego wyniku niż w generacji 0 co można zauważyć na wykresie 6. Podczas gdy prawdopodobieństwo mutacji będzie wysokie (np. 70%) wynik naszego algorytmu będzie bardzo losowy. Nie da się przewidzieć czy w ciągu kilku kolejnych generacji będziemy w stanie uzyskać lepsze rozwiązanie ponieważ jest to bardzo losowe. Z reguły najlepsza wartość crossowania to od 70% do 90%, a mutacji od 1% do 3%.

Badanie wpływu parametru wielkości populacji i ilości generacji na wynik

Parametry oprócz numberOfPopulation oraz numberOfGenerations nie uległy zmianie względem podanych na początku sprawozdania.

numberOfPopulation = 20


numberOfGenerations = 100



Wykres 9

numberOfPopulation = 1000

numberOfGenerations = 15



Wykres 10

Wnioski: Gdy wielkość populacji będzie małą wartością to niezależnie od ilości generacji nasz algorytm nie będzie w stanie wygenerować nowych, lepszych rozwiązań. Spowodowane jest to małą różnorodnością genotypów w generacji 0, która uniemożliwia otrzymanie większej ilości różnych i lepszych genotypów. Podobnie jest w sytuacji gdy ilość naszych generacji jest mała. Nie jesteśmy w stanie otrzymać wystarczającej ilości genotypów.

